

DNA C4.5

Rafał Kwiatkowski, Franciszek Sioma

26 maja 2020

1 Opis projektu

1.1 Cel projektu

Celem projektu *DNA C4.5* było stworzenie aplikacji wykorzystującej algorytm C4.5 do rozpoznawania w zadanej sekwencji kodującej białko jednego z dwóch możliwych miejsc rozcięcia - donora lub akceptora. Zadanie zatem sprowadza się do dwóch rozłącznych zadań:

- rozróżnianie prawdziwych donorów od sekwencji je przypominających
- rozróżnianie prawdziwych akceptorów od sekwencji je przypominających

W naszym programie przyjęliśmy kolejne znaki w sekwencji kodującej jako atrybuty danego przykładu.

1.2 Wkład autorów

- Algorytm C4.5 - Rafał Kwiatkowski
- Testy i eksperymenty - Franciszek Sioma
- Dokumentacja - Franciszek Sioma, Rafał Kwiatkowski

1.3 Decyzje projektowe

Zdecydowaliśmy się zaimplementować algorytm wykorzystując drzewo dowolne(niebinarne). Dzięki temu, ograniczyliśmy głębokość drzewa, co za tym idzie klasyfikacja powinna średnio przebiegać szybciej. Minusem tej decyzji jest klasyfikacja drzewa o wartościach dotąd nieznanych w procesie uczenia. Rozwiązaniem tego problemu jest dodanie klasy domyślnej dla przykładów, które drzewo nie jest w stanie sklasyfikować. W związku z tym, że w naszej przestrzeni możliwych klas znajdują się tylko dwie, mówiące czy dany wycinek kodu genetycznego jest akceptorem(lub donorem w zależności od problemu), zdecydowaliśmy się w takich przypadkach stwierdzać, że dany przykład nie jest akceptorem(bądź też donorem).

W ramach eksperymentów postanowiliśmy użyć walidacji krzyżowej, dzięki której jesteśmy pewni, że przetestowaliśmy cały zbiór danych. Wykorzystaliśmy K-krotną walidację z parametrem k równym 10.

1.4 Wykorzystane narzędzia i biblioteki

Do napisania aplikacji użyliśmy języka Python w wersji: 3.8, dokumentacja została stworzona przy użyciu języka Latex, a IDE z którego korzystaliśmy to Visual Studio Code. Użyliśmy również systemu kontroli wersji Git. Link do repozytorium: <https://github.com/Rolfrider/C4.5-Gene-Splicing>

2 Uruchamianie aplikacji i odtworzenie wyników testów

W przypadku tego projektu pracowaliśmy na konkretnych zbiorach danych i nasza aplikacja służy tylko do przeprowadzenia testów, dlatego jest tylko jeden sposób jej uruchomienia. W celu odtworzenia przeprowadzonych testów należy wykonać komendę:

```
python app.py
```

3 Eksperymenty

W naszym projekcie przeprowadziliśmy walidację krzyżową dla parametru k równego 10 dla drzewa utworzonego przez algorytm ID3 oraz dla drzewa utworzonego przez C4.5. Test został powtórzony 100 razy, a uśrednione wyniki zostały przedstawione poniżej. Celem tego testu jest sprawdzenie czy algorytm C4.5 uzyskuje lepsze wyniki niż ID3 będący częścią algorytmu C4.5. Taka sytuacja powinna wystąpić jeżeli dla testowanych danych występuje zjawisko przetrenowania przy algorytmie ID3.

3.1 Wyniki

Algorytm	Średnie dopasowanie
ID3	81,5%
C4.5	81,4%

Tablica 1: Wyniki walidacji krzyżowej dla akceptorów

Algorytm	Średnie dopasowanie
ID3	83,2%
C4.5	81,7%

Tablica 2: Wyniki walidacji krzyżowej dla donorów

Z wyników walidacji wynika, że drzewo przed zastosowaniem algorytmu C4.5 daje lepszą dokładność wyników niż po. Algorytm C4.5 przyspiesza działanie programu na utworzonym drzewie oraz pozwala uniknąć nadmiernego dopasowania. Wyniki świadczą o tym, że w naszym przypadku zjawisko to nie występowało na tyle często by polepszyć końcowy wynik, a wręcz przeciwnie.